# 管理工作负载

## ONTAP 9

NetApp
February 01, 2022

This PDF was generated from https://docs.netapp.com/zh-cn/ontap/performance-admin/identify-remaining-performance-capacity-task.html on February 01, 2022. Always check docs.netapp.com for the latest.

# 目录

管理工作负载 1
确定剩余性能容量 1
确定高流量客户端或文件 2
通过 QoS 保证吞吐量 4

# 管理工作负载

## 确定剩余性能容量

性能容量（或 _余 量 _ ）用于衡量在资源上的工作负载性能开始受到延迟影响之前，您可以在节点或聚合上执行多少工作。了解集群上的可用性能容量有助于您配置和平衡工作负载。

此任务需要高级权限级别命令。

您可以对 ` -object` 选项使用以下值来收集和显示性能余量统计信息：

- 对于 CPU ，请 `resource_er余 量 _cpu` 。
- 对于聚合，请 `resource_sc余 量 _aggr` 。

您也可以使用 System Manager 和 Active IQ Unified Manager 完成此任务。

步骤

1. 更改为高级权限级别：

   ```
   set -privilege advanced
   ```

2. 开始实时性能余量统计信息收集：

   ```
   satictics start - object resource_e余 _cpu_aggr
   ```

   有关完整的命令语法，请参见手册页。

3. 显示实时性能余量统计信息：

   ```
   satictics show -object resource_sc余 _cpu_aggr
   ```

   有关完整的命令语法，请参见手册页。

4. 返回到管理权限：

   ```
   set -privilege admin
   ```

以下示例显示了集群节点的平均每小时性能余量统计信息。

您可以通过从 `optimal_point_utilization` 计数器中减去 `current_utilization` 计数器来计算节点的可用性能容量。在此示例中， `CPU_sti2520-213` 的利用率容量为 -14% （ 72%-86% ），这表明 CPU 在过去一小时内平均已过度利用。

您可以指定 `EMA_daily` ， `EMA_weekly` 或 `EMA_monthly` 来获取较长时间内的平均信息。

```
sti2520-2131454963690::*> statistics show -object resource_headroom_cpu
-raw -counter ewma_hourly
  (statistics show)

Object: resource_headroom_cpu
Instance: CPU_sti2520-213
Start-time: 2/9/2016 16:06:27
End-time: 2/9/2016 16:06:27
Scope: sti2520-213

    Counter                                                     Value
    -------------------------------- ---------------------------------
    ewma_hourly                                                     -
                         current_ops                             4376
                     current_latency                            37719
                current_utilization                               86
                  optimal_point_ops                             2573
              optimal_point_latency                             3589
           optimal_point_utilization                              72
     optimal_point_confidence_factor                               1

Object: resource_headroom_cpu
Instance: CPU_sti2520-214
Start-time: 2/9/2016 16:06:27
End-time: 2/9/2016 16:06:27
Scope: sti2520-214

    Counter                                                     Value
    -------------------------------- ---------------------------------
    ewma_hourly                                                     -
                         current_ops                                0
                     current_latency                                0
                current_utilization                                 0
                  optimal_point_ops                                 0
              optimal_point_latency                                 0
           optimal_point_utilization                               71
     optimal_point_confidence_factor                               1
2 entries were displayed.
```

## 确定高流量客户端或文件

您可以使用 ONTAP 活动对象技术来确定造成集群流量过大的客户端或文件。确定这些 " 排名前 " 的客户端或文件后，您可以重新平衡集群工作负载或执行其他步骤来解决问题描述。

您必须是集群管理员才能执行此任务。

步骤

1. 查看访问集群的前几个客户端：

   `satictics top client show -node` *node_name* `-sort-key` *sort_column* `-interval` *seconds_between _updates*-迭 代 迭 代 _ *-max _number_of_instances*

   有关完整的命令语法，请参见手册页。

   以下命令显示访问 `cluster1` 的前几个客户端：

```
cluster1::> statistics top client show

cluster1 : 3/23/2016 17:59:10


                                                 *Total
        Client Vserver           Node Protocol    Ops
-------------- ------- -------------- -------- ------
172.17.180.170     vs4 siderop1-vsim4      nfs    668
172.17.180.169     vs3 siderop1-vsim3      nfs    337
172.17.180.171     vs3 siderop1-vsim3      nfs    142
172.17.180.170     vs3 siderop1-vsim3      nfs    137
172.17.180.123     vs3 siderop1-vsim3      nfs    137
172.17.180.171     vs4 siderop1-vsim4      nfs     95
172.17.180.169     vs4 siderop1-vsim4      nfs     92
172.17.180.123     vs4 siderop1-vsim4      nfs     92
172.17.180.153     vs3 siderop1-vsim3      nfs      0
```

2. 查看在集群上访问的前几个文件：

   `satictics top file show -node` *node_name* `-sort-key` *sort_column* `-interval` *seconds_between _updates* -迭 代 迭 代 _ *-max _number_of_instances*

   有关完整的命令语法，请参见手册页。

   以下命令显示在 `cluster1` 上访问的前几个文件：

```
cluster1::> statistics top file show

cluster1 : 3/23/2016 17:59:10

                                    *Total
                     File Volume Vserver          Node    Ops
------------------------ ------ ------- -------------- ------
/vol/vol1/vm170-read.dat   vol1     vs4 siderop1-vsim4     22
/vol/vol1/vm69-write.dat   vol1     vs3 siderop1-vsim3      6
     /vol/vol2/vm171.dat   vol2     vs3 siderop1-vsim3      2
     /vol/vol2/vm169.dat   vol2     vs3 siderop1-vsim3      2
      /vol/vol2/p123.dat   vol2     vs4 siderop1-vsim4      2
      /vol/vol2/p123.dat   vol2     vs3 siderop1-vsim3      2
     /vol/vol1/vm171.dat   vol1     vs4 siderop1-vsim4      2
     /vol/vol1/vm169.dat   vol1     vs4 siderop1-vsim4      2
     /vol/vol1/vm169.dat   vol1     vs4 siderop1-vsim3      2
      /vol/vol1/p123.dat   vol1     vs4 siderop1-vsim4      2
```

# 通过 QoS 保证吞吐量

## QoS 概述保证吞吐量

您可以使用存储服务质量（ QoS ）来保证关键工作负载的性能不会因争用资源的工作负载而降级。您可以为争用资源的工作负载设置吞吐量上限，以限制其对系统资源的影响，也可以为关键工作负载设置吞吐量上限，以确保满足最小吞吐量目标，而不管争用资源的工作负载有何需求。您甚至可以为同一工作负载设置上限和下限。

### 关于吞吐量上限（ QoS 最大值）

吞吐量上限会将工作负载的吞吐量限制为最大 IOPS 或 MBps 数，或者 IOPS 和 MBps 数。在下图中，工作负载 2 的吞吐量上限可确保它不会 " 抢占 " 工作负载 1 和 3 。

策略组定义了一个或多个工作负载的吞吐量上限。工作负载表示 _storage 对象： _ 卷，文件， qtree 或 LUN ，或者 SVM 中的所有卷，文件， qtree 或 LUN 的 I/O 操作。您可以在创建策略组时指定上限，也可以等到监控工作负载之后再指定上限。

> 工作负载的吞吐量可能会超出指定上限 10% ，尤其是在工作负载的吞吐量发生快速变化时。要处理突发事件，上限可能会超过 50% 。令牌累积率高达 150% 时，单个节点上发生突发

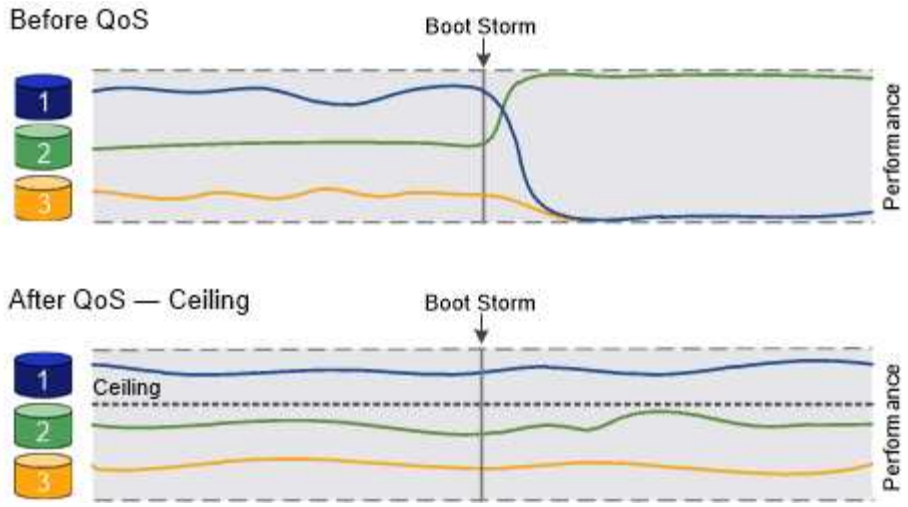


关于吞吐量下限（ **QoS** 最小值）

吞吐量下限可确保工作负载的吞吐量不低于最小 IOPS 或 MBps 或 IOPS 和 MBps 数。在下图中，工作负载 1 和工作负载 3 的吞吐量下限可确保满足最小吞吐量目标，而不管工作负载 2 的需求如何。

> 如示例所示，吞吐量上限会直接限制吞吐量。吞吐量下限会优先考虑设置了下限的工作负载，从而间接限制吞吐量。

定义吞吐量下限的策略组不能应用于 SVM 。您可以在创建策略组时指定下限，也可以等到监控工作负载之后再指定下限。

> 在 ONTAP 9.7 之前的版本中，如果有足够的可用性能容量，则可以保证吞吐量下限。在 ONTAP 9.7 及更高版本中，即使可用性能容量不足，也可以保证吞吐量下限。这种新的楼层行为称为 Floor v2 。为了满足保证要求，对于没有吞吐量下限的工作负载或超出下限设置的工作负载，Floor v2 可能会导致延迟更高。第 2 层适用场景 QoS 和自适应 QoS 。在 ONTAP 9.7P6 及更高版本中，可以选择启用 / 禁用楼层 v2 的新行为。在执行 `volume move trigger-cutover` 等关键操作期间，工作负载可能会低于指定的楼层。即使有足够的可用容量且未执行关键操作，工作负载的吞吐量也可能会低于指定下限 5% 。如果楼层配置过度，并且没有性能容量，则某些工作负载可能会低于指定的楼层。

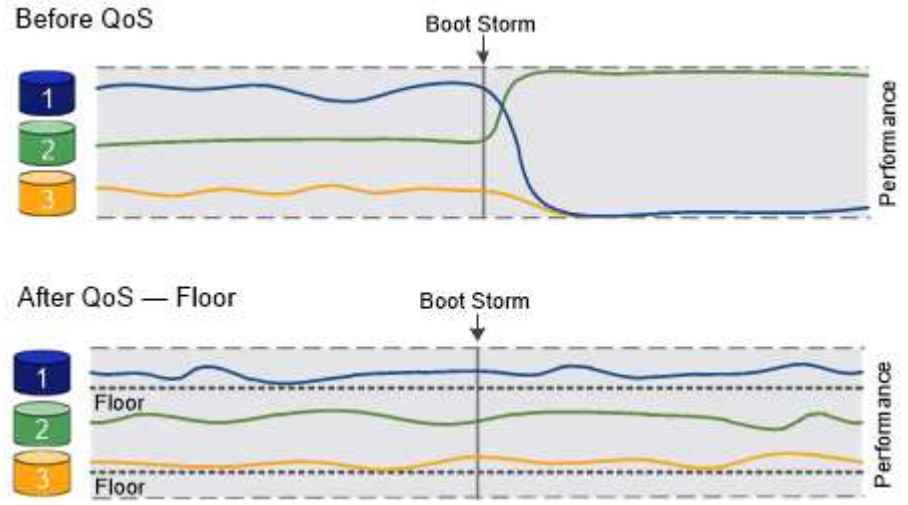

关于共享和非共享 **QoS** 策略组

从 ONTAP 9.4 开始，您可以使用 *non-shared* QoS 策略组分别指定每个成员工作负载的已定义吞吐量上限或下限适用场景。*shared* 策略组的行为取决于策略类型：

- 对于吞吐量上限，分配给共享策略组的工作负载的总吞吐量不能超过指定的上限。
- 对于吞吐量下限，共享策略组只能应用于单个工作负载。

关于自适应 **QoS**

通常，分配给存储对象的策略组值是固定的。当存储对象的大小发生变化时，您需要手动更改此值。例如，增加卷上的已用空间量通常需要相应地增加为卷指定的吞吐量上限。

*Adaptive QoS* 会自动将策略组值扩展到工作负载大小，并在工作负载大小发生变化时保持 IOPS 与 TBSGB 的比率。如果您要在大型部署中管理数百或数千个工作负载，则这是一项显著优势。

通常，您可以使用自适应 QoS 来调整吞吐量上限，但也可以使用它来管理吞吐量下限（当工作负载大小增加时）。工作负载大小表示为存储对象分配的空间或存储对象使用的空间。

> 在 ONTAP 9.5 及更高版本中，已用空间可用于吞吐量下限。在 ONTAP 9.4 及更早版本中，吞吐量下限不支持此功能。

- 已分配空间策略会根据存储对象的标称大小保持 IOPS/TBGB 比率。如果此比率为 100 IOPS/GB ，则只要 150 GB 卷保持此大小，其吞吐量上限将为 15 ， 000 IOPS 。如果将卷大小调整为 300 GB ，则自适应 QoS 会将吞吐量上限调整为 30 ， 000 IOPS 。
- 已用空间策略（默认值）会根据存储效率之前存储的实际数据量保持 IOPS/TBGB 比率。如果此比率为 100 IOPS/GB ，则存储了 100 GB 数据的 150 GB 卷的吞吐量上限为 10 ， 000 IOPS 。随着已用空间量的变化，自适应 QoS 会根据比率调整吞吐量上限。

从 ONTAP 9.5 开始，您可以为应用程序指定 I/O 块大小，以便以 IOPS 和 MBps 为单位表示吞吐量限制。MBps 限制是通过块大小乘以 IOPS 限制计算得出的。例如，如果 I/O 块大小为 32 K ，而 IOPS 限制为 6144IOPS/TB ，则 MBps 限制为 192 MBps 。

吞吐量上限和下限均会出现以下行为：

- 将工作负载分配给自适应 QoS 策略组后，上限或下限将立即更新。
- 调整自适应 QoS 策略组中的工作负载大小后，上限或下限大约会在五分钟内更新。

在进行更新之前，吞吐量必须至少增加 10 IOPS 。

自适应 QoS 策略组始终为非共享组：定义的吞吐量上限或每个成员工作负载的下限适用场景。

从 ONTAP 9.6 开始，采用 SSD 的 ONTAP Select Premium 支持吞吐量下限。

常规支持

下表显示了在支持吞吐量上限，吞吐量下限和自适应 QoS 方面的差异。

| 资源或功能 | 吞吐量上限 | 吞吐量下限 | 吞吐量下限 v2 | 自适应 QoS |
|---|---|---|---|---|

| ONTAP 9 版本 | 全部 | 9.2 及更高版本 | 9.7 及更高版本 | 9.3 及更高版本 |
| --- | --- | --- | --- | --- |
| 平台 | 全部 | • AFF<br>• C190 *<br>• 采用 SSD * 的 ONTAP Select 高级版 | • AFF<br>• C190<br>• 采用 SSD 的 ONTAP Select 高级版 | 全部 |
| 协议 | 全部 | 全部 | 全部 | 全部 |
| FabricPool | 是的。 | 是，如果分层策略设置为 " 无 " 且云中没有块。 | 是，如果分层策略设置为 " 无 " 且云中没有块。 | 是的。 |
| SnapMirror 同步 | 是的。 | 否 | 否 | 是的。 |

ONTAP Select 9.6 版开始支持 * 。 c190 和 ONTAP 。

支持的工作负载达到吞吐量上限

下表按 ONTAP 9 版本显示了工作负载对吞吐量上限的支持。不支持根卷，负载共享镜像和数据保护镜像。

| 工作负载支持—上限 | 9.0 | 9.1 | 9.2 | 9.3 | 9.4 及更高版本 | 9.8 及更高版本 |
| --- | --- | --- | --- | --- | --- | --- |
| Volume | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 |
| 文件 | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 |
| LUN | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 |
| SVM | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 |
| FlexGroup 卷 | 否 | 否 | 否 | 是的。 | 是的。 | 是的。 |
| qtree* | 否 | 否 | 否 | 否 | 否 | 是的。 |
| 每个策略组具有多个工作负载 | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 | 是的。 |
| 非共享策略组 | 否 | 否 | 否 | 否 | 是的。 | 是的。 |

- 从 ONTAP 9.8 开始，在启用了 NFS 的 FlexVol 和 FlexGroup 卷的 qtree 中支持 NFS 访问。从 ONTAP 9.1.1 开始，启用了 SMB 的 FlexVol 和 FlexGroup 卷的 qtree 也支持 SMB 访问。

支持吞吐量下限的工作负载

下表按 ONTAP 9 版本显示了吞吐量下限的工作负载支持。不支持根卷，负载共享镜像和数据保护镜像。

| 工作负载支持—楼层 | 9.2 | 9.3 | 9.4 及更高版本 | 9.8 及更高版本 |
|---|---|---|---|---|
| Volume | 是的。 | 是的。 | 是的。 | 是的。 |
| 文件 | 否 | 是的。 | 是的。 | 是的。 |
| LUN | 是的。 | 是的。 | 是的。 | 是的。 |
| SVM | 否 | 否 | 否 | 是的。 |
| FlexGroup 卷 | 否 | 否 | 是的。 | 是的。 |
| qtree * | 否 | 否 | 否 | 是的。 |
| 每个策略组具有多个工作负载 | 否 | 否 | 是的。 | 是的。 |
| 非共享策略组 | 否 | 否 | 是的。 | 是的。 |

- 从 ONTAP 9.8 开始，在启用了 NFS 的 FlexVol 和 FlexGroup 卷的 qtree 中支持 NFS 访问。从 ONTAP 9.1.1 开始，启用了 SMB 的 FlexVol 和 FlexGroup 卷的 qtree 也支持 SMB 访问。

自适应 **QoS** 支持的工作负载

下表显示了 ONTAP 9 版本对自适应 QoS 的工作负载支持。不支持根卷，负载共享镜像和数据保护镜像。

| 工作负载支持—自适应 QoS | 9.3 | 9.4 及更高版本 |
|---|---|---|
| Volume | 是的。 | 是的。 |
| 文件 | 否 | 是的。 |
| LUN | 否 | 是的。 |
| SVM | 否 | 否 |
| FlexGroup 卷 | 否 | 是的。 |
| 每个策略组具有多个工作负载 | 是的。 | 是的。 |
| 非共享策略组 | 是的。 | 是的。 |

工作负载和策略组的最大数量

下表按 ONTAP 9 版本显示了工作负载和策略组的最大数量。

| 工作负载支持 | 9.3 及更早版本 | 9.4 及更高版本 |
| --- | --- | --- |
| 每个集群的最大工作负载数 | 12,000 | 40,000 |
| 每个节点的最大工作负载数 | 12,000 | 40,000 |
| 最大策略组数 | 12,000 | 12,000 |

## 启用或禁用吞吐量下限 v2

您可以在 AFF 上启用或禁用吞吐量下限 v2 。默认值为 enabled 。如果启用了楼层 v2 ，则在控制器大量使用时，以其他工作负载更高的延迟为代价，可以满足吞吐量下限。第 2 层适用场景 QoS 和自适应 QoS 。

步骤

1. 更改为高级权限级别：

   ```
   set -privilege advanced
   ```

2. 输入以下命令之一：

   | 如果您要 ... | 使用以下命令： |
   | --- | --- |
   | 禁用楼层 v2 | `qos settings through-floor-v2 -enable false` |
   | 启用楼层 v2 | `qos settings through-floor-v2 -enable true` |

   > 要在 MetroCluster 集群中禁用吞吐量下限 v2 ，必须运行
   >
   > `qos settings through-floor-v2 -enable false`
   >
   > 命令。

   ```
   cluster1::*> qos settings throughput-floors-v2 -enable false
   ```

## 存储 QoS 工作流

如果您已经知道要使用 QoS 管理的工作负载的性能要求，则可以在创建策略组时指定吞吐量限制。否则，您可以等到监控工作负载之后再指定限制。

## 使用 QoS 设置吞吐量上限

您可以使用策略组的 `max-throughput` 字段为存储对象工作负载定义吞吐量上限（QoS 最大值）。您可以在创建或修改存储对象时应用策略组。

您需要什么？ **#8217**；将需要什么

- 您必须是集群管理员才能创建策略组。
- 要将策略组应用于 SVM，您必须是集群管理员。

关于此任务

- 从 ONTAP 9.4 开始，您可以使用 *non-shared* QoS 策略组来指定定义的吞吐量上限适用场景每个成员工作负载。否则，策略组为 _shared： _ 分配给策略组的工作负载的总吞吐量不能超过指定的上限。

  为 `qos policy-group create` 命令设置 `-is-shared=false` 以指定非共享策略组。

- 您可以指定 IOPS， MB/ 秒或 IOPS， MB/ 秒上限的吞吐量限制如果同时指定 IOPS 和 MB/ 秒，则会强制执行首先达到的限制。

  > 如果为同一工作负载设置了上限和下限，则只能以 IOPS 为单位指定上限的吞吐量限制。

- 受 QoS 限制的存储对象必须包含在策略组所属的 SVM 中。多个策略组可以属于同一个 SVM。
- 如果某个存储对象的包含对象或子对象属于某个策略组，则不能将该存储对象分配给该策略组。
- QoS 最佳实践是将策略组应用于相同类型的存储对象。

步骤

1. 创建策略组。

   `qos policy-group create -policy-group` *`policy_group`* `-vserver` *`svm`* `-max -throughput` *`number_of_IOPS`*`|MB/S_IOPS , MB/s -is-shared true_false`

   有关完整的命令语法，请参见手册页。您可以使用 `qos policy-group modify` 命令调整吞吐量上限。

   以下命令将创建最大吞吐量为 5， 000 IOPS 的共享策略组 `pg-vs1`：

   ```
   cluster1::> qos policy-group create -policy-group pg-vs1 -vserver vs1
   -max-throughput 5000iops -is-shared true
   ```

   以下命令将创建非共享策略组 `pg-vs3`，最大吞吐量为 100 IOPS 和 400 KB/S：

   ```
   cluster1::> qos policy-group create -policy-group pg-vs3 -vserver vs3
   -max-throughput 100iops,400KB/s -is-shared false
   ```

   以下命令将创建非共享策略组 `pg-vs4` 而不设置吞吐量限制：

```
cluster1::> qos policy-group create -policy-group pg-vs4 -vserver vs4
-is-shared false
```

2. 将策略组应用于 SVM ，文件，卷或 LUN：

   ` *storage_object_create -vserver _svm* -qos-policy-group *policy_group*`

   有关完整的命令语法，请参见手册页。您可以使用 ` _storage_object_modify` 命令将其他策略组应用于存储对象。

   以下命令会将策略组 `pg-vs1` 应用于 SVM `vs1`：

```
cluster1::> vserver create -vserver vs1 -qos-policy-group pg-vs1
```

   以下命令会将策略组 `pg-app` 应用于卷 `app1` 和 `App2`：

```
cluster1::> volume create -vserver vs2 -volume app1 -aggregate aggr1
-qos-policy-group pg-app
```

```
cluster1::> volume create -vserver vs2 -volume app2 -aggregate aggr1
-qos-policy-group pg-app
```

3. 监控策略组性能：

   `QoS` 统计信息性能显示

   有关完整的命令语法，请参见手册页。

   > 从集群监控性能。请勿使用主机上的工具监控性能。

   以下命令显示策略组性能：

```
cluster1::> qos statistics performance show
Policy Group           IOPS      Throughput   Latency
-------------------- -------- --------------- ----------
-total-                 12316       47.76MB/s  1264.00us
pg_vs1                   5008       19.56MB/s     2.45ms
_System-Best-Effort        62       13.36KB/s     4.13ms
_System-Background         30           0KB/s        0ms
```

4. 监控工作负载性能：

`QoS` 统计信息工作负载性能显示

有关完整的命令语法，请参见手册页。

> 从集群监控性能。请勿使用主机上的工具监控性能。

以下命令显示工作负载性能：

```
cluster1::> qos statistics workload performance show
Workload          ID     IOPS      Throughput    Latency
--------------- ------ -------- ---------------- ----------
-total-              -    12320        47.84MB/s  1215.00us
app1-wid7967      7967     7219        28.20MB/s   319.00us
vs1-wid12279     12279     5026        19.63MB/s     2.52ms
_USERSPACE_APPS     14       55        10.92KB/s   236.00us
_Scan_Backgro..   5688       20            0KB/s        0ms
```

> 您可以使用 `qos statistics workload latency show` 命令查看 QoS 工作负载的详细延迟统计信息。

## 使用 **QoS** 设置吞吐量下限

您可以使用策略组的 `min-throughput` 字段为存储对象工作负载定义吞吐量下限（ QoS 最小值）。您可以在创建或修改存储对象时应用策略组。从 ONTAP 9.8 开始，您可以以 IOPS 或 MBps 或 IOPS 和 MBps 为单位指定吞吐量下限。

您需要什么？ **#8217**；将需要什么

- 您必须运行 ONTAP 9.2 或更高版本。从 ONTAP 9.2 开始，吞吐量下限可用。
- 您必须是集群管理员才能创建策略组。

关于此任务

- 从 ONTAP 9.4 开始，您可以使用 *non-shared* QoS 策略组来指定将定义的吞吐量下限分别应用于每个成员工作负载。只有在这种情况下，吞吐量下限的策略组才能应用于多个工作负载。

  为 `qos policy-group create` 命令设置 ` -is-shared=false` 以指定非共享策略组。

- 如果节点或聚合上的性能容量（余量）不足，则工作负载的吞吐量可能会低于指定的下限。
- 受 QoS 限制的存储对象必须包含在策略组所属的 SVM 中。多个策略组可以属于同一个 SVM 。
- QoS 最佳实践是将策略组应用于相同类型的存储对象。
- 定义吞吐量下限的策略组不能应用于 SVM 。

步骤

1. 检查节点或聚合上是否有足够的性能容量，如 perMalink： identify-remning-performability-capacity-task.html[ 确定剩余性能容量 ] 中所述。

2. 创建策略组。

   `qos policy-group create -policy group` *`policy_group`* `-vserver` *`svm`* `-min -throughput` *`qos_target`* `-is-shared true_false`

   有关完整的命令语法，请参见适用于您的 ONTAP 版本的手册页。您可以使用 `qos policy-group modify` 命令调整吞吐量下限。

   以下命令将创建最小吞吐量为 1， 000 IOPS 的共享策略组 `pg-vs2`：

   ```
   cluster1::> qos policy-group create -policy group pg-vs2 -vserver vs2
   -min-throughput 1000iops -is-shared true
   ```

   以下命令将创建非共享策略组 `pg-vs4` 而不设置吞吐量限制：

   ```
   cluster1::> qos policy-group create -policy group pg-vs4 -vserver vs4
   -is-shared false
   ```

3. 将策略组应用于卷或 LUN：

   ` *storage_object_create -vserver _svm* -qos-policy-group *policy_group*`

   有关完整的命令语法，请参见手册页。您可以使用 ` _storage_object_modify` 命令将其他策略组应用于存储对象。

   以下命令会将策略组 `pg-app2` 应用于卷 `App2`：

   ```
   cluster1::> volume create -vserver vs2 -volume app2 -aggregate aggr1
   -qos-policy-group pg-app2
   ```

4. 监控策略组性能：

   `QoS` 统计信息性能显示

   有关完整的命令语法，请参见手册页。

   > 从集群监控性能。请勿使用主机上的工具监控性能。

   以下命令显示策略组性能：

```
cluster1::> qos statistics performance show
Policy Group           IOPS      Throughput   Latency
-------------------- -------- --------------- ----------
-total-                 12316       47.76MB/s  1264.00us
pg_app2                  7216       28.19MB/s   420.00us
_System-Best-Effort        62       13.36KB/s     4.13ms
_System-Background         30           0KB/s        0ms
```

5. 监控工作负载性能：

   `QoS` 统计信息工作负载性能显示

   有关完整的命令语法，请参见手册页。

   > 从集群监控性能。请勿使用主机上的工具监控性能。

   以下命令显示工作负载性能：

```
cluster1::> qos statistics workload performance show
Workload          ID     IOPS      Throughput    Latency
--------------- ------ -------- ---------------- ----------
-total-              -    12320        47.84MB/s  1215.00us
app2-wid7967      7967     7219        28.20MB/s   319.00us
vs1-wid12279     12279     5026        19.63MB/s     2.52ms
_USERSPACE_APPS     14       55        10.92KB/s   236.00us
_Scan_Backgro..   5688       20            0KB/s        0ms
```

   > 您可以使用 `qos statistics workload latency show` 命令查看 QoS 工作负载的详细延迟统计信息。

## 使用自适应 **QoS** 策略组

您可以使用 *adaptive QoS* 策略组自动将吞吐量上限或下限扩展到卷大小，从而在卷大小发生变化时保持 IOPS 与 TBSGB 的比率。如果您要在大型部署中管理数百或数千个工作负载，则这是一项显著优势。

您需要什么？ **#8217** ；将需要什么

- 您必须运行 ONTAP 9.3 。自 ONTAP 9.3 起，可使用自适应 QoS 策略组。
- 您必须是集群管理员才能创建策略组。

存储对象可以是自适应策略组或非自适应策略组的成员，但不能同时是这两者。存储对象的 SVM 和策略必须相同。存储对象必须处于联机状态。

自适应 QoS 策略组始终为非共享组：定义的吞吐量上限或每个成员工作负载的下限适用场景。

吞吐量限制与存储对象大小的比率取决于以下字段的交互：

- `expected-IOPS` 是每个已分配 TB-GB 的最小预期 IOPS 。

> 只能在 `AFF` 平台上保证预期 `IOPS` 。只有当分层策略设置为 " 无 " 且云中没有块时，FabricPool 才会保证 `expected-IOPS` 。对于未建立 SnapMirror 同步关系的卷，可以保证 `expected-IOPS` 。

- `peak-IOPS` 是每个已分配或已使用 TB-GB 的最大可能 IOPS 。
- `expected-IOPS-allocation` 指定预期 IOPS 是使用已分配空间（默认值）还是已用空间。

> `expected-IOPS-allocation` 适用于 ONTAP 9.5 及更高版本。ONTAP 9.4 及更早版本不支持此功能。

- `peak-IOPS-allocation` 指定是将已分配空间还是已用空间（默认值）用于 `peak-IOPS` 。
- `ab`绝对 最小 `IOPS` 是绝对最小 IOPS 数。您可以对非常小的存储对象使用此字段。当 `abory-min-IOPS` 大于计算得出的 `expected-IOPS` 时，它会同时覆盖 `peak-IOPS` 和 / 或 `expected-IOPS` 。

  例如，如果将 `expected-IOPS` 设置为 1 ， 000 IOPS/TB ，并且卷大小小于 1 GB ，则计算的 `expected-IOPS` 将为一个百分比 IOP 。计算得出的 峰值 `IOPS` 将是更小的比例。您可以通过将 `abisy-min-IOPS` 设置为实际值来避免这种情况。

- `block-size` 指定应用程序 I/O 块大小。默认值为 32 K 。有效值为 8K ， 16K ， 32K ， 64K ，任意。any 表示不强制实施块大小。

可用的三个默认自适应 QoS 策略组如下表所示。您可以将这些策略组直接应用于卷。

| 默认策略组 | 预期 IOPS/TB | 峰值 IOPS/TB | 绝对最小 IOPS |
|---|---|---|---|
| 至高 | 6,144 | 12,288 | 1000 |
| 性能 | 2 ， 048 | 4,096 | 500 |
| 值 | 128. | 512 | 75 |

步骤

1. 创建自适应 QoS 策略组：

   ```
   qos adaptive-policy-group create -policy group policy_group -vserver svm
   -expected-IOPS number_of_IOPS/TB_GB -pease-IOPS number_of_IOPS/TB_GB -expected
   -IOPS-allocation-space lused-space -pease-IOPS- allocation allocated-space|
   used-space| used-space -used-space - used-space - used-space - used-space -
   used -space - space- used -space - space- used -space - space- space- space-
   space- space
   ```

   有关完整的命令语法，请参见手册页。

ONTAP 9.5 及更高版本中提供了 ` -expected-IOPS-allocation` 和 ` -block-size` 。ONTAP 9.4 及更早版本不支持这些选项。

以下命令将创建自适应 QoS 策略组 `adpg-app1` ，其中 ` -expected-IOPS` 设置为 300 IOPS/TB ， ` -peak -IOPS` 设置为 1 ， 000 IOPS/TB ， ` -peak-IOPS-allocation` 设置为 `used-space` ， ` -abrey-min-IOPS` 设置为 50 IOPS：

```
cluster1::> qos adaptive-policy-group create -policy group adpg-app1
-vserver vs2 -expected-iops 300iops/tb -peak-iops 1000iops/TB -peak-iops
-allocation used-space -absolute-min-iops 50iops
```

2. 将自适应 QoS 策略组应用于卷：

   `volume create -vserver SVM -volume` *`volume`*`-aggregate` *`aggregate`* `-size` *`number_of_TB_GB -qos-adaptive-policy-group _policy_group`*

   有关完整的命令语法，请参见手册页。

   以下命令会将自适应 QoS 策略组 `adpg-app1` 应用于卷 `app1`：

```
cluster1::> volume create -vserver vs1 -volume app1 -aggregate aggr1
-size 2TB -qos-adaptive-policy-group adpg-app1
```

   以下命令会将默认的自适应 QoS 策略组 至 至新卷 `app4` 和现有卷 `app5` 。为策略组适用场景 volumes `app4` 和 `app5` 分别定义的吞吐量上限：

```
cluster1::> volume create -vserver vs4 -volume app4 -aggregate aggr4
-size 2TB -qos-adaptive-policy-group extreme
```

```
cluster1::> volume modify -vserver vs5 -volume app5 -qos-adaptive-policy
-group extreme
```

**Copyright Information**

Copyright © 2022 NetApp, Inc. All rights reserved. Printed in the U.S. No part of this document covered by copyright may be reproduced in any form or by any means-graphic, electronic, or mechanical, including photocopying, recording, taping, or storage in an electronic retrieval system- without prior written permission of the copyright owner.

Software derived from copyrighted NetApp material is subject to the following license and disclaimer:

THIS SOFTWARE IS PROVIDED BY NETAPP “AS IS” AND WITHOUT ANY EXPRESS OR IMPLIED WARRANTIES, INCLUDING, BUT NOT LIMITED TO, THE IMPLIED WARRANTIES OF MERCHANTABILITY AND FITNESS FOR A PARTICULAR PURPOSE, WHICH ARE HEREBY DISCLAIMED. IN NO EVENT SHALL NETAPP BE LIABLE FOR ANY DIRECT, INDIRECT, INCIDENTAL, SPECIAL, EXEMPLARY, OR CONSEQUENTIAL DAMAGES (INCLUDING, BUT NOT LIMITED TO, PROCUREMENT OF SUBSTITUTE GOODS OR SERVICES; LOSS OF USE, DATA, OR PROFITS; OR BUSINESS INTERRUPTION) HOWEVER CAUSED AND ON ANY THEORY OF LIABILITY, WHETHER IN CONTRACT, STRICT LIABILITY, OR TORT (INCLUDING NEGLIGENCE OR OTHERWISE) ARISING IN ANY WAY OUT OF THE USE OF THIS SOFTWARE, EVEN IF ADVISED OF THE POSSIBILITY OF SUCH DAMAGE.

NetApp reserves the right to change any products described herein at any time, and without notice. NetApp assumes no responsibility or liability arising from the use of products described herein, except as expressly agreed to in writing by NetApp. The use or purchase of this product does not convey a license under any patent rights, trademark rights, or any other intellectual property rights of NetApp.

The product described in this manual may be protected by one or more U.S. patents, foreign patents, or pending applications.

RESTRICTED RIGHTS LEGEND: Use, duplication, or disclosure by the government is subject to restrictions as set forth in subparagraph (c)(1)(ii) of the Rights in Technical Data and Computer Software clause at DFARS 252.277-7103 (October 1988) and FAR 52-227-19 (June 1987).

**Trademark Information**

NETAPP, the NETAPP logo, and the marks listed at http://www.netapp.com/TM are trademarks of NetApp, Inc. Other company and product names may be trademarks of their respective owners.